HPA – High Performance Architectures

TOP 500 SUPERCOMPUTERS REPORT

TOP 13: Isambard-AI phase 2

Trinidad Salvador, Luis Miguel[1]

11/10/2026

[1]lmtrinidadsalvador@gmail.com

***Abstract* — El presente proyecto toma como fin la descripción a distintos niveles del clúster Isambard-AI phase 2. Se aborda de forma jerárquica**

---

1. Introduction

Desde la invención del primer microprocesador comercial, el intel 4004 en 1971, hasta la actualidad, la capacidad computacional ha experimentado un crecimiento exponencial. Sin embargo, este crecimiento converge hoy hacia su asíntota debido a los límites físicos y termodinámicos que rigen la industria de los semiconductores. Históricamente, durante las últimas décadas siglo XX y principios del XXI, el aumento de rendimiento se fundamentó en dos pilares teóricos: el escalado de Dennard [1] y la ley de Moore [2].

El escalado de Dennard, formalizado por Robert H. Dennard [1], establecía que al reducir las dimensiones físicas de los transistores, el voltaje y la corriente debían escalar de forma proporcional. Esto permitía incrementar de forma lineal la frecuencia de reloj con la miniaturización litográfica, manteniendo constante la densidad de potencia por área. No obstante, este paradigma colapsó [3] a principios de la década de los 2000, cuando los avances en litografía hicieron que comenzasen a manifestarse de forma significativa los efectos de la mecánica cuántica. Específicamente, la aparición del efecto túnel electrónico impidió seguir reduciendo el voltaje umbral, desatando corrientes de fuga insostenibles y cristalizando la barrera de potencia (power wall).

Paralelamente, la ley de Moore [2], que inicialmente predecía la duplicación de la densidad de transistores anualmente, y posteriormente de forma bianual [4], ha sufrido una severa ralentización atribuida tanto al incremento exponencial del coste del equipamiento necesario para las nuevas litografías EUV [5], como a la aproximación a los límites atómicos del silicio. La desaceleración de este modelo ha llevado recientemente al planteamiento de nuevos paradigmas de escalado basados en la minimización de los retrasos de la propagación de señales mediante el paso de arquitecturas 2D a integración vertical [6].

Ante el estancamiento del escalado vertical basado en frecuencia, la respuesta de la industria consistió en la explotación sistemática del escalado horizontal y el paralelismo a nivel de hilos (TLP) [7]. AMD fue pionera en la transición hacia procesadores multinúcleo x86 en 2005, con la introducción del Athlon 64 X2 de diseño monolítico nativo[8]. Dos décadas después, la explotación del TLP en sistemas de memoria compartida ha alcanzado métricas sin precedentes, como demuestra la sexta generación de procesadores AMD EPYC, capaces de integrar hasta 256 núcleos por *socket* [9].

Pese a este drástico escalado, los procesadores de propósito general exhiben ineficiencias arquitectónicas frente a cargas de trabajo altamente paralelizables. Estos problemas requieren del uso de aceleradores especializados, como las unidades de procesamiento gráfico (GPU), que rescinden del control de flujo monohilo en favor del paradigma paralelo SIMT. No obstante, los requerimientos contemporáneos no solo exceden la capacidad computacional de un único circuito integrado, sino también la capacidad de transferencia de datos de las unidades de memoria a las de cómputo. El desequilibrio histórico entre el rápido aumento de la capacidad de cómputo y el mas lento aumento del ancho de banda de memoria da lugar a un cuello de memoria sistémico, que fue por primera vez presentado en 1995 [10], y que cobra cada vez mas relevancia en el ámbito del entrenamiento de grandes modelos de lenguaje tal como refleja Gholami et Al [11].

Para poder sortear este cuello de botella y abordar el cómputo a exaescala, resulta imperativo

el despliegue de clústeres heterogéneos interconectados mediante topologías de red de alto ancho de banda y baja latencia. En el contexto geopolítico, esta infraestructura masiva resulta crítica para el entrenamiento y desarrollo de grandes modelos de lenguaje con el fin de garantizar la soberanía tecnológica nacional.

En este marco de *IA soberana* se fundamenta el proyecto estratégico AI Research Resource (AIRR) [12] del gobierno Británico, junto al Bristol Centre for SuperComputing [13], ambos responsables de Isambard-AI phase 2, la infraestructura de supercomputación orientada a IA mas avanzada de Reino Unido.

El presente informe desglosará de manera analítica y sistemática el clúster Isambard-AI phase 2, actual decimotercer puesto en la lista TOP500 [14]. Para ello, se adopta una aproximación arquitectónica jerárquica: partiendo de la infraestructura física subyacente y las instalaciones (Facility Level), seguida del análisis estructural de los bastidores y la topología de la interconexión de red, la evaluación de la jerarquía de memoria del sistema y, finalmente, la caracterización microarquitectónica de los nodos computacionales, concluyendo con una validación empírica y teórica mediante benchmarks de rendimiento.

2. Facility level system overview

A alto nivel, el cluster Isambard-AI está formado por un total de 5448 superchips *NVIDIA GH200* (Grace Hopper) [15] distribuidos a lo largo de 13 racks de alta densidad. El primer rack, un HPE Cray EX2500 pertenece al supercomputador Isambard-AI phase 1, mientras que los otros 12 racks, HPE Cray EX4000, pertenecen al superordenadoer Isambard-AI phase 2 [16], el que se desglosa en el presente documento.

El superordenador opera bajo un consumo energético de 5 MW, proporcionando una potencia computacional máxima de 216.50 Pflops en `FP64` en el benchmark Linpack [14]. Por otro lado, gracias a la arquitectura tensorial proporcionada por las GPU Nvidia, es capaz de alcanzar de forma teórica 21 EFlops/s en formato FP8 [16].

2.1. Brief history of the project

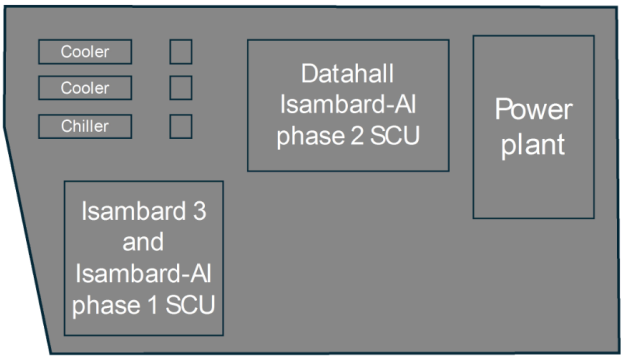
La concepción del sistema responde de forma directa a políticas de soberanía de datos y seguridad nacional. A diferencia de infraestructuras paneuropeas desarrolladas bajo el consorcio EuroHPC, el gobierno británico desarrolló su propia estrategia bajo el programa *AI Research Resource* (AIRR) [12]. Esta iniciativa gubernamental supuso la inyección inicial de 225 millones de libras esterlinas en otoño de 2023. [17]

La ejecución del proyecto recayó en la universidad de Bristol debido a su experiencia probada con el proyecto GW4 [18]. Concretamente, el clúster está bajo la supervisión del Prof. Simon McIntosh-Smith, director del *Bristol Centre for Supercomputing* (BriCS), y la Dra. Sadaf Alam, directora de tecnología (CTO) de la misma institución. El sistema fue ensamblado colaborativamente por Hewlett Packard Enterprise (HPE) y NVIDIA, y a pesar de la complejidad logística del mismo, la fase 1 fue completada en tiempo récord, pasando de la firma del contrato a un estado operacional en menos de 4 meses.



2.2. Facilities

El sistema físico se aloja en el *National Composites Centre* (NCC), ubicado en el *Bristol and Bath Science Park* . Comparte recinto con la fase 1 del proyecto Isambard-AI, así como con el cluster Isambard 3, basado exclusivamente en CPU Nvidia Grace . Debido a las estrictas limitaciones espaciales, con tan solo 550 metros cuadrados disponibles ($15.6 \times 35m$), el sistema no podía ser desplegado en una sala blanca convencional. En su lugar, se implementó una solución autocontenida que encapsula nodos, transformación eléctrica, y estaciones de bombeo dentro del propio habitáculo. Para ello se empleó una arquitectura de centro de datos modular, lo que permitió reducir un 72% de las emisiones derivadas de su construcción en comparación con los centros de datos convencionales.



Para disipar la alta densidad de energía térmica generada, que excede los 400 kW por rack, el uso de refrigeración por aire convencional se presenta inviable. En su lugar, se emplea Refrigeración Líquida Directa, solución estandarizada en los chasis HPE Cray Ex. Esta aproximación no solo evita el sobrecalentamiento de los componentes, sino que su eficiencia convierte al sistema en un referente del paradigma Green AI, posicionandose su supercomputador gemelo, el Isambard AI-phase 1 en el puesto 4 del ranking Green AI de junio de 2026 [19]. Este hito en sostenibilidad es especialmente reseñable al haber sido alcanzado mediante aceleradores de la generación Hopper, los cuales exhiben consumos nominales por flop superiores en comparación con arquitecturas litográficamente mas avanzadas, como Blackwell o Vera Rubin. El sistema ostenta una Efectividad del Uso de la Energía (PUE) nominal de 1.08, lo que implica que que solo el 8% de la energía se destina a refrigeración periférica.

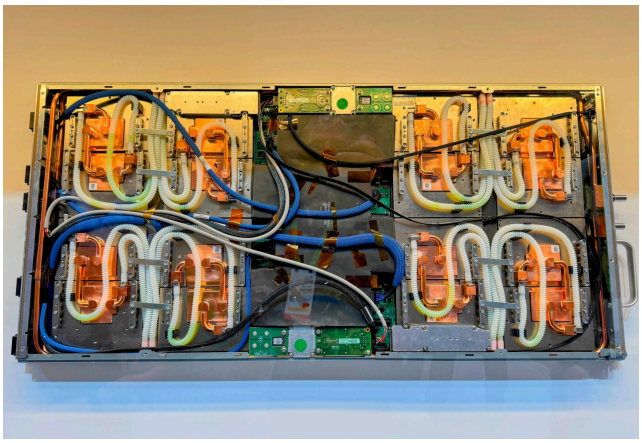
El impacto mediambiental derivado del consumo de la máquina se minimiza a través de su política de aprovisionamiento eléctrico. Si bien su alto consumo de 5MW implicó la necesidad de una conexión de alta capacidad directa a la red eléctrica nacional británica, el 100% de la energía suministrada al sistema procede de fuentes renovables de Reino Unido, abarcando no solo sitemas eólicos, solares e hidroeléctricos, sino también sistemas de almacenamiento en baterías .

3. Rack & System Interconnect Level

La arquitectura a nivel de rack e interconexión está diseñada de forma jerárquica para maximizar la densidad de cómputo y minimizar la latencia, respondiendo a las exigencias operacionales de las cargas de trabajo de inteligencia artifical contemporáneas.

A nivel de bastidor, cada uno de los 12 HPE Cray EX4000 [16] disponibles contiene un total de 110 nodos computacionales, lo que proporciona un total de 440 superchips NVIDIA GH200 por armario.

Dentro de cada rack, la unidad básica es el *blade* acelerador HPE Cray EX254n. Esta placa aloja dos nodos computacionales independientes, cada uno de los cuales cuenta con 4 procesadores NVIDIA Grace de 72 núcleos (arquitectura ARM Neoverse V2), así como 4 GPU NVIDIA H100 (arquitectura Hopper). Consecuentemente, cada nodo dispone de 288 núcleos ARM v9 y 4 GPUS H100.



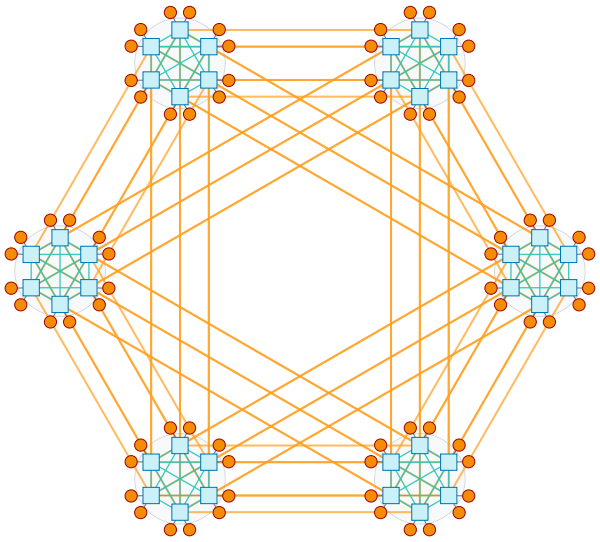
A nivel de interconexión del cluster, la orquestración de la red se delega en la arquitectura HPE Slingshot 11 [20]. El sistema HPE Cray EX utiliza un acoplamiento ortogonal sin cables : los chasis de cómputo se insertan por la parte frontal del chasis, mientras que los chásis de conmutación (switches) se insertan por la parte trasera, intersectando en un midplane. Este diseño cumple fundamentalmente con 3 objetivos:

- **Mejorar la integridad de señal:** permitiendo mayor ancho de banda.
- **Minimizar las latencias de interconexión:** el reducido trazado permite minimizar los retrasos en tiempo de propagación.
- **Minimizar el gasto energético:** reduciendo la cantidad de energía necesaria por byte transmitido.

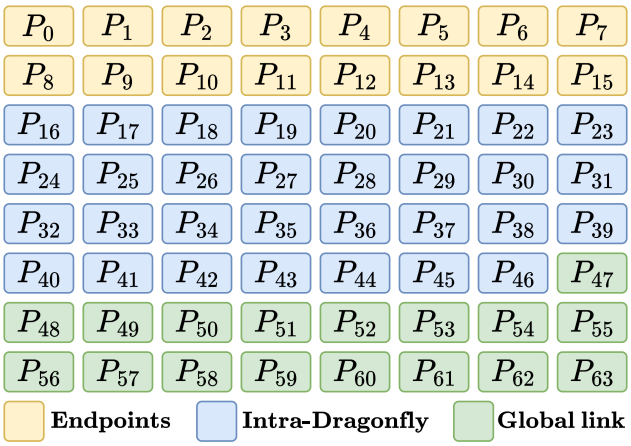
Cada nodo hace uso de 4 tarjetas de red, ofreciendo un ancho de banda total de 800 Gb/s de entrada y salida simultánea [13] por nodo hacia la red principal. Para la interconexión entre nodos se hace uso de switches de 64 puertos, que ofrecen un total de 25.6Tb/s.

A nivel macroscópico, la topología de red empleada es de tipo *Dragonfly*. Este diseño toma

como base enmallados all-to-all de pequeños grupos de nodos, que se interconectan posteriormente entre sí, esto permite garantizar un diámetro de 3 saltos [20] para ≤ 37120 endpoints.



Aunque se desconoce la implementación exacta de esta topología en el clúster Isambard-AI phase 2, es posible inferir, usando como referencia otros sistemas, como el sistema *Alps*, perteneciente al *Swiss National Supercomputing Centre* [21]. Una posible implementación de esta arquitectura para cada switch se ofrece en la figura .



4. Memory Hierarchy Architecture

Detalle aquí las conclusiones de su trabajo.

5. Processor & Accelerator Microarchitecture

6. Empirical Performance & Benchmarks

7. Theoretical Correlations & Quantitative Analysis

Bibliography

[1] R. Dennard, F. Gaensslen, H.-N. Yu, V. Rideout, E. Bassous, and A. LeBlanc, "Design of ion-implanted MOSFET's with very small physical dimensions," *IEEE Journal of Solid-State Circuits*, vol. 9, no. 5, pp. 256–268, 1974, doi: 10.1109/JSSC.1974.1050511.

[2] G. E. Moore, "Cramming more components onto integrated circuits, Reprinted from Electronics, volume 38, number 8, April 19, 1965, pp.114 ff.," *IEEE Solid-State Circuits Society Newsletter*, vol. 11, no. 3, pp. 33–35, 2006, doi: 10.1109/N-SSC.2006.4785860.

[3] M. Bohr, "A 30 Year Retrospective on Dennard's MOSFET Scaling Paper," *IEEE Solid-State Circuits Society Newsletter*, vol. 12, no. 1, pp. 11–13, 2007, doi: 10.1109/N-SSC.2007.4785534.

[4] G. E. Moore, "Progress in digital integrated electronics [Technical literaiture, Copyright 1975 IEEE. Reprinted, with permission. Technical Digest. International Electron Devices Meeting, IEEE, 1975, pp. 11-13.]," *IEEE Solid-State Circuits Society Newsletter*, vol. 11, no. 3, pp. 36–37, 2006, doi: 10.1109/N-SSC.2006.4804410.

[5] M. M. Waldrop, "The chips are down for Moore's law," *Nature*, vol. 530, pp. 144–147, 2016, [Online]. Available: https://api.semanticscholar.org/CorpusID:4464555

[6] T. He, "A time scaling theory for multi-layer electronic systems," *Science China Information Sciences*, vol. 69, no. 8, p. 183401, Jul. 2026, doi: 10.1007/s11432-026-5028-5.

[7] L. Peng, J.-K. Peir, T. K. Prakash, T. C. Chen, and P. K. Ong, "Memory performance

and scalability of Intel's and AMD's dual-core processors," in *2007 IEEE International Performance, Computing, and Communications Conference (IPCCC)*, 2007, pp. 55–64. doi: 10.1109/IPCCC.2007.358877.

[8] A. M. Devices, "AMD Athlon™ 64 X2 Dual-Core Processor Product Data Sheet." Jan. 2007. [Online]. Available: https://pdf.directindustry.com/viewerCatalog/amd/amd-athlon-64-x2-dual-core-processor-product-data-sheet/102295-390197.html

[9] A. M. Devices, "AMD EPYC™ Server CPU Architecture and Performance Overview," Whitepaper, 2026. [Online]. Available: https://www.amd.com/content/dam/amd/en/documents/epyc-business-docs/white-papers/amd-epyc-9006-server-cpus-architectural-leadership.pdf

[10] W. A. Wulf and S. A. McKee, "Hitting the memory wall: implications of the obvious," *SIGARCH Comput. Archit. News*, vol. 23, no. 1, pp. 20–24, Mar. 1995, doi: 10.1145/216585.216588.

[11] A. Gholami, Z. Yao, S. Kim, C. Hooper, M. W. Mahoney, and K. Keutzer, "AI and Memory Wall," *IEEE Micro*, vol. 44, no. 3, pp. 33–39, May 2024, doi: 10.1109/MM.2024.3373763.

[12] I. Department for Science and Technology, "AI Research Resource." [Online]. Available: https://www.gov.uk/government/publications/ai-research-resource

[13] Bristol Centre for Supercomputing, "2025: Isambard-AI - 12 month journey." [Online]. Available: https://www.bristol.ac.uk/research/centres/bristol-supercomputing/articles/2025/isambard-ai%E2%80%9412-month-journey.html

[14] TOP500, "Isambard-AI phase 2 - HPE Cray EX254n, NVIDIA Grace 72C 3.1GHz, NVIDIA GH200 Superchip, Slingshot-11." [Online]. Available: https://top500.org/system/180388/

[15] N. Corporation, "NVIDIA GH200 Grace Hopper Superchip Architecture: Performance and Productivity for Strong-Scaling HPC and Giant AI Workloads," Santa Clara, CA, Whitepaper v1.21, 2024. [Online]. Available: https://dam-cdn.nvd.orangelogic.com/AssetLink/h125m07nuew832vthbov0q6b2rs8ta0q.pdf

[16] S. McIntosh-Smith, S. Alam, and C. Woods, "Isambard-AI: a leadership-class supercomputer optimised specifically for Artificial Intelligence," in CUG '24. Perth, Australia: Association for Computing Machinery, 2025, pp. 44–54. doi: 10.1145/3725789.3725794.

[17] H. P. Enterprise, "UK Government Invests £225M to Create UK's Most Powerful AI Supercomputer with University of Bristol and Hewlett Packard Enterprise." [Online]. Available: https://www.hpe.com/us/en/newsroom/press-release/2023/11/uk-government-invests-225m-to-create-uks-most-powerful-ai-supercomputer-with-university-of-bristol-and-hewlett-packard-enterprise.html

[18] S. McIntosh-Smith, J. Price, A. Poenaru, and T. Deakin, "Scaling Results From the First Generation of Arm-based Supercomputers," in *CUG 2019 proceedings*, May 2019.

[19] TOP500, "Green500 List – June 2026." [Online]. Available: https://www.top500.org/lists/green500/green500-june-2026/

[20] H. P. E. D. LP, "HPE Slingshot Switches QuickSpecs," technical report a50002546enw-16701-Worldwide V14, Jul. 2026. [Online]. Available: https://www.hpe.com/psnow/doc/a50002546enw.pdf?ver=14

[21] D. De Sensi *et al.*, "Exploring GPU-to-GPU Communication: Insights into Supercomputer Interconnects," in *SC24: International Conference for High Performance Computing, Networking, Storage and Analysis*, 2024, pp. 1–15. doi: 10.1109/SC41406.2024.00039.